

IDENTIFICANDO ALZHEIMER EM CÉREBROS

Análise de dados de MRI através de uma rede de convolução com canais profundos

Pedro Dalla Vecchia Chaves

Motivação

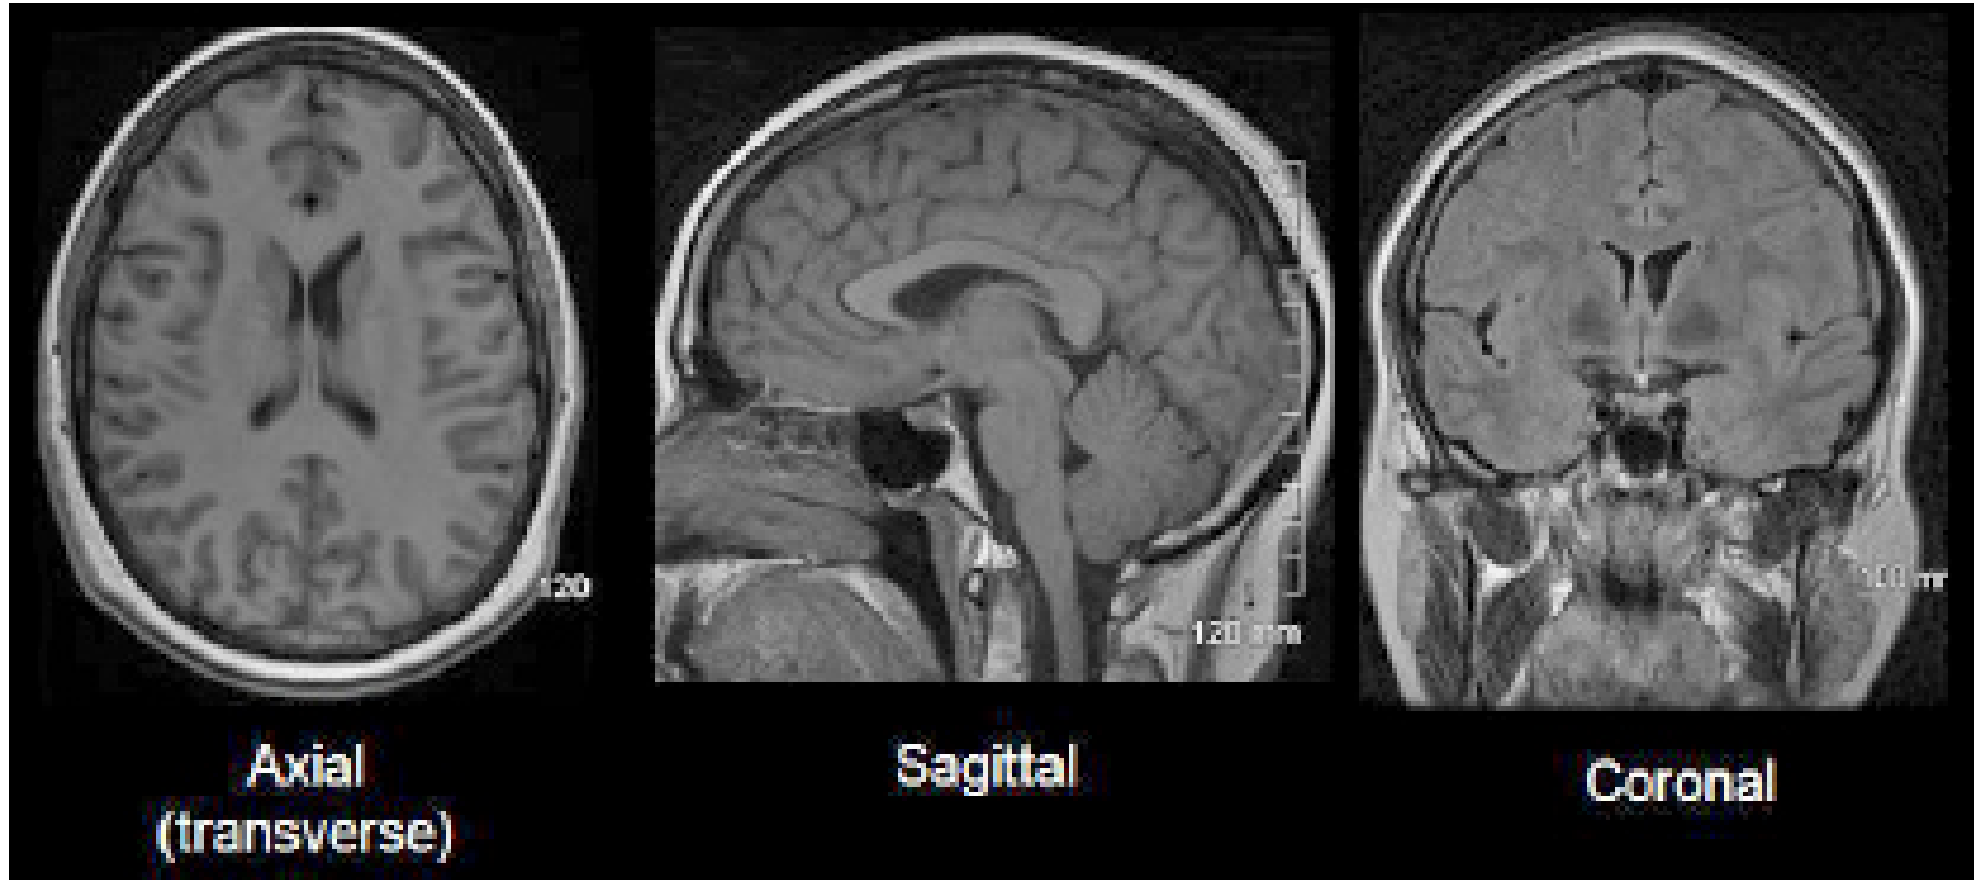
Cerca de 47 milhões de pessoas no mundo possuem a doença de Alzheimer e as estimativas são de que esse número dobre a cada 20 anos. Os custos relacionados ao Alzheimer são estimados em um trilhão de dólares para 2018. Tendo em vista essa situação foi desenvolvido uma ferramenta de análise de imagens de ressonância magnética através de redes de convolução para prever a presença da doença, bem como a identificação de cérebros normais.

Dados

Os dados de ressonância magnética foram obtidos do Alzheimer’s Disease Neuroimaging Initiative (ADNI), em um estudo de aproximadamente 3 anos. Foram utilizadas 1704 imagens (62% de cérebros normais e 38% de cérebros diagnosticados com alzheimer) de 417 pacientes diferentes, com idade variando de 50 a 95 anos.is.


Metodologia

Foi utilizada uma rede convolucional com intuito de classificar em qual grupo (normal ou com alzheimer) a imagem pertencia. Como entrada a rede recebe 128 cortes do plano



Planos de corte do cérebro

coronal de um cérebro. Para garantir uma entrada padrão para a rede, todas as imagens foram pré- processadas com interpolação cúbica (para garantir orientação correta) e um subsampling foi feito para um “shape” em comum (128x128x128). Tal pré-processamento foi feito utilizando Nilearn, um módulo em Python de aprendizado de máquina orientado para análise estatística de neuro imagens. A saída da rede é um vetor de probabilidades para os dois grupos, no qual o índice de maior probabilidade indica o grupo a qual o cérebro pertence.




Arquitetura da rede convolução

Para construir a rede, foi utilizada a API para modelos de redes neurais Keras (com backend TensorFlow). A implementação das convoluções foi feita de uma forma diferente e inovadora: ao invés de aplicar convoluções 3D na imagem de ressonância por completo, utilizou-se convolução 2D, colocando nos canais as imagens de somente um dos 3 planos (coronal). Dessa forma o tempo de treinamento foi expressivamente reduzido, em comparação com a convolução 3D. Os experimentos foram feitos com 50 épocas e 20 instâncias como tamanho de batch. Utilizou-se 5-fold cross-validation, com imagens de treino, validação e teste vindas de pacientes diferentes, de modo a garantir uma análise das métricas com maior confiança. Durante o treinamento foi aplicada a técnica de “early stopping” (com nível de espera de 10 épocas) de modo a evitar overfitting. Com a técnica de convolução aplicada, o tempo médio de cada época foi de 40 segundos, o que permitiu fazer diferentes experimentos de forma rápida utilizando uma GPU Tesla K40.

Resultados


Os resultados foram reportados em função das seguintes métricas: acurácia, precisão, revocação e F1 (média ponderada entre precisão e revocação) de ambos os grupos (normal e com alzheimer). Os valores abaixo se referem a média e o desvio padrão entre os 5-folds.

	Acurácia	Precisão	Revocação	F1
Normal	60.55% (+/- 3.61)	69.64% (+/- 12.91)	68.13% (+/-12.91)	67.53% (+/-6.14)
Alzheimer	60.55% (+/- 3.61)	48.28% (+/- 9.39)	48.73% (+/-17.60)	46.95% (+/-9.06)




Para explorar como se deu o aprendizado da rede em termos de poder de representação, a saída da primeira camada densa dos dados de teste foi obtida, gerando vetores de dimensão 1024. Esses vetores foram passados como entrada para o algoritmo de redução de dimensionalidade t-SNE de forma a buscar uma representação bidimensional do aprendizado da rede, com o intuito de visualizar os possíveis clusters de classificação

Para comparar diferentes possíveis representações, variou-se o parâmetro perplexity do t-SNE, que balanceia a atenção entre aspectos locais e globais dos dados de entrada.



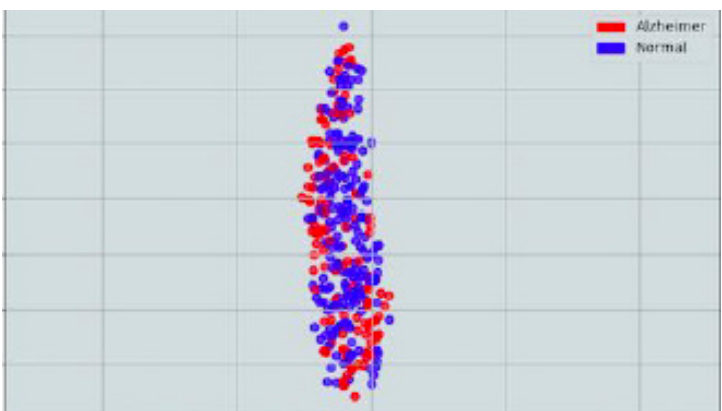
t-SNE: perplexity = 35



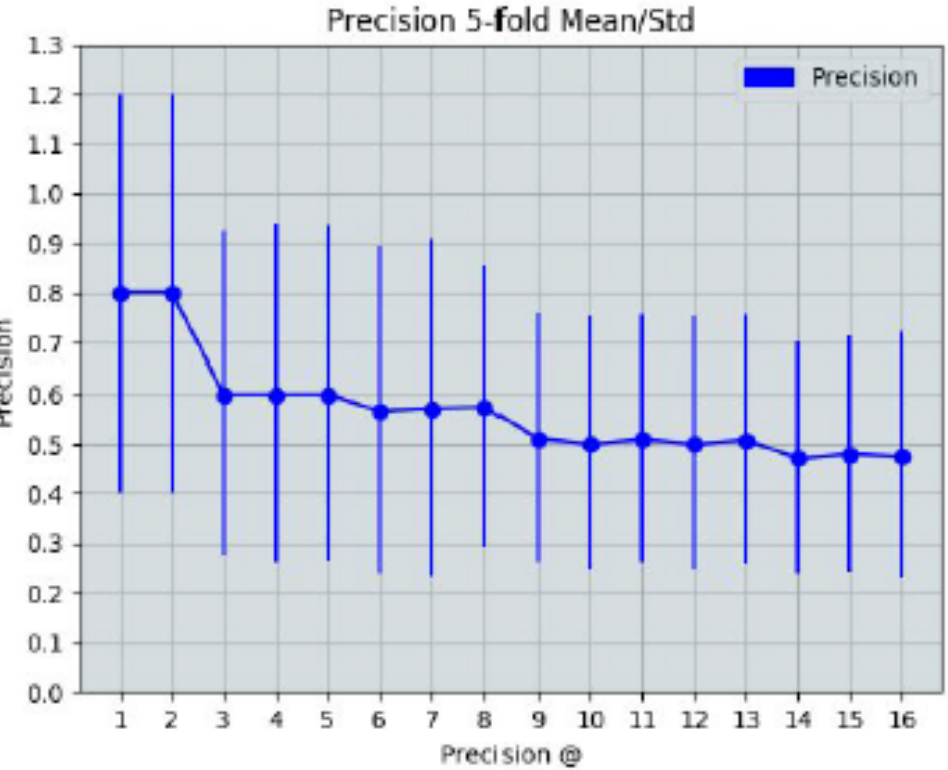
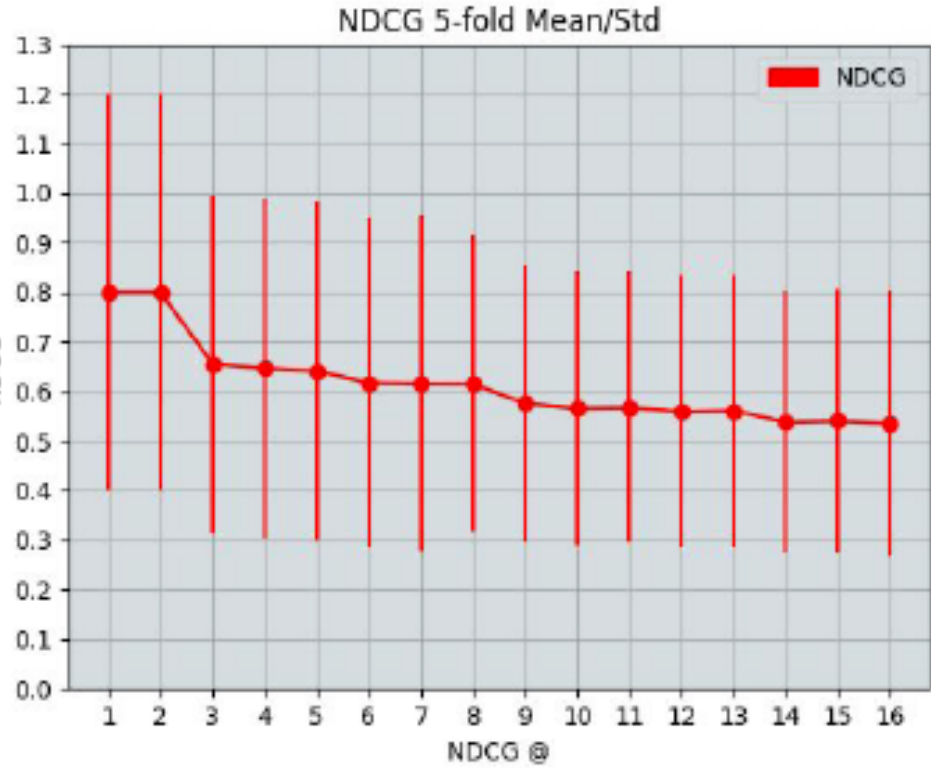
t-SNE: perplexity = 40

Por último foram avaliadas as métricas NDCG (Normalized Discounted Cumulative Gain), Precision e MAP (Mean Average Precision), normalmente utilizadas em sistemas de recomendação, mas que podem ser úteis na avaliação da qualidade de um ranqueamento. Ou seja, em relação às probabilidades dadas à chance de um cérebro ter alzheimer, o quão efetivas elas foram.

	Mean	Std
MAP	0.3903	0.0931



t-SNE: perplexity = 50



Trabalhos Futuros

Com intuito de melhorar os resultados obtidos serão feitos experimentos em busca de melhores hiperparâmetros para a rede de convolução por meio de random search e algoritmos genéticos.

